Université Côte d'Azur
Master 1 Informatique - Parcours Intelligence Artificielle

Détection de Similarité Sémantique dans les Questions Médicales

Application du modèle BioBERT et pipeline multilingue

Auteur :
Ibrahima CAMARA

Technologies : PyTorch, Hugging Face, BioBERT, Streamlit

Version mise à jour – 19 octobre 2026

Table des matières

1 Introduction **2**

2 Données **2**

3 Architecture technique **2**
3.1 Le modèle : BioBERT 2
3.2 Implémentation PyTorch 2

4 Analyse des résultats **3**
4.1 Résultats finaux 3
4.2 Courbe d'apprentissage et overfitting 3

5 Déploiement et interface utilisateur **3**
5.1 Pipeline de traduction (multilinguisme) 3
5.2 Démonstration 4

6 Limites et perspectives **4**

7 Conclusion **5**

1 Introduction

L'explosion des demandes sur les plateformes de télémédecine crée un besoin d'automatisation. Un défi majeur est la redondance : les patients posent souvent la même question médicale avec des formulations très différentes.

Ce projet présente un système capable de détecter si deux questions sont sémantiquement équivalentes. Nous utilisons le *transfer learning* : le modèle **BioBERT** est fine-tuné sur un corpus de paires de questions médicales, puis déployé dans une interface qui accepte le français et l'anglais.

2 Données

Le jeu de données est `medical_questions_pairs` (Hugging Face) : 3 048 paires de questions médicales, équilibrées (50 % similaires, 50 % différentes). Une prédiction au hasard donne donc 50 % d'accuracy, ce qui sert de référence.

Les données sont séparées en 80 % pour l'entraînement et 20 % pour le test (`random_state=42`). Chaque question apparaît dans deux paires du jeu de données. Avec une séparation aléatoire, une même question peut donc se retrouver à la fois dans l'entraînement et dans le test. Cela peut rendre les résultats un peu optimistes (voir la section 6).

3 Architecture technique

3.1 Le modèle : BioBERT

Nous avons choisi le modèle pré-entraîné `dmis-lab/biobert-base-cased-v1.2`. Contrairement à BERT standard, BioBERT a été pré-entraîné sur des articles biomédicaux (PubMed), ce qui l'aide à comprendre des termes comme *hypertension*, *myocardial infarction* ou *analgesic*.

Les deux questions sont données ensemble au modèle sous la forme `[CLS] Q1 [SEP] Q2 [SEP]` (longueur maximale 128 tokens). Une couche de classification à 2 sorties (classe 0 : différentes, classe 1 : similaires) est ajoutée, puis une fonction softmax donne les probabilités.

3.2 Implémentation PyTorch

Le projet a été migré de TensorFlow vers **PyTorch**. L'entraînement a été réalisé sur GPU (NVIDIA T4) via Google Colab, avec la classe `Trainer` de Hugging Face. Le listing 1 montre la configuration utilisée. Les paramètres non indiqués gardent les valeurs par défaut de la bibliothèque (taux d'apprentissage 5e-5, optimiseur AdamW, sans weight decay).

Listing 1: Configuration de l'entraînement

```
training_args = TrainingArguments(
    output_dir='./results',
    num_train_epochs=3,
    per_device_train_batch_size=16,
    per_device_eval_batch_size=16,
    logging_steps=50,
    evaluation_strategy="epoch",
    save_strategy="no"
)
```

4 Analyse des résultats

4.1 Résultats finaux

Après 3 époques, le modèle obtient sur le jeu de test :

Métrique	Valeur
Accuracy	83,77 %
F1-score	0,8411
Référence (hasard)	50 %

4.2 Courbe d'apprentissage et overfitting

Une expérience complémentaire sur 10 époques permet d'observer l'évolution de la perte (*loss*) sur l'entraînement (bleu) et sur le jeu de test (rouge). La figure 1 la présente.

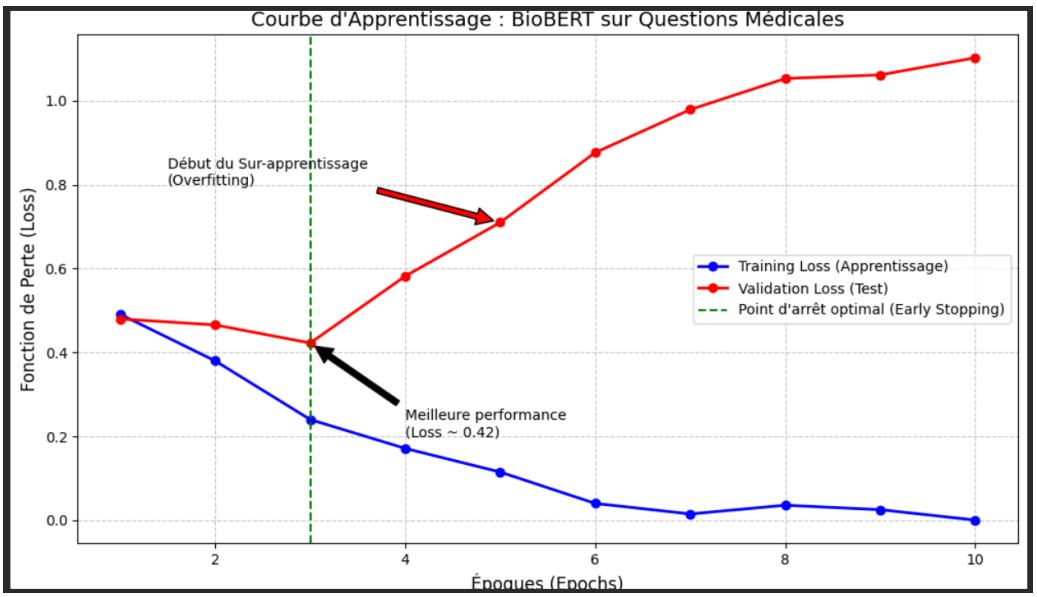


Figure 1: Perte d'entraînement et de test sur 10 époques : le sur-apprentissage apparaît après l'époque 3.

Interprétation. La perte de test est minimale à l'époque 3 ($\approx 0{,}42$), puis elle remonte alors que la perte d'entraînement continue de descendre vers 0. Le modèle apprend alors les données par cœur au lieu de généraliser : c'est du sur-apprentissage. Nous avons donc choisi un entraînement de **3 époques**. Ce choix a été fait à la main, en lisant la courbe. Il n'y a pas d'arrêt automatique (*early stopping*).

5 Déploiement et interface utilisateur

Le modèle est publié sur le Hugging Face Hub (`Ibrahima20/bert-question-pairs-similarity`) et chargé automatiquement par l'application **Streamlit**.

5.1 Pipeline de traduction (multilinguisme)

BioBERT est un modèle anglais. L'application traduit donc les questions vers l'anglais avant de les envoyer au modèle.

Changement par rapport à la première version. La traduction passait par le service gratuit Google Translate (bibliothèque `deep-translator`). Ce service limite le nombre de requêtes et peut bloquer l'application avec l'erreur *"too many requests"*. Il a été remplacé par un modèle de traduction **local** : `Helsinki-NLP/opus-mt-fr-en` (MarianMT). Les avantages :

- aucune limite de requêtes et aucune dépendance à un service externe ;
- fonctionnement sans internet après le premier téléchargement (environ 300 Mo) ;
- les données saisies ne sont pas envoyées à un tiers, ce qui est utile pour des questions de santé ;
- un cache évite de traduire deux fois la même phrase.

La bibliothèque `langdetect` détecte la langue : un texte déjà en anglais n'est pas traduit. Le modèle de traduction couvre le sens français → anglais, ce qui correspond au besoin de l'application.

5.2 Démonstration

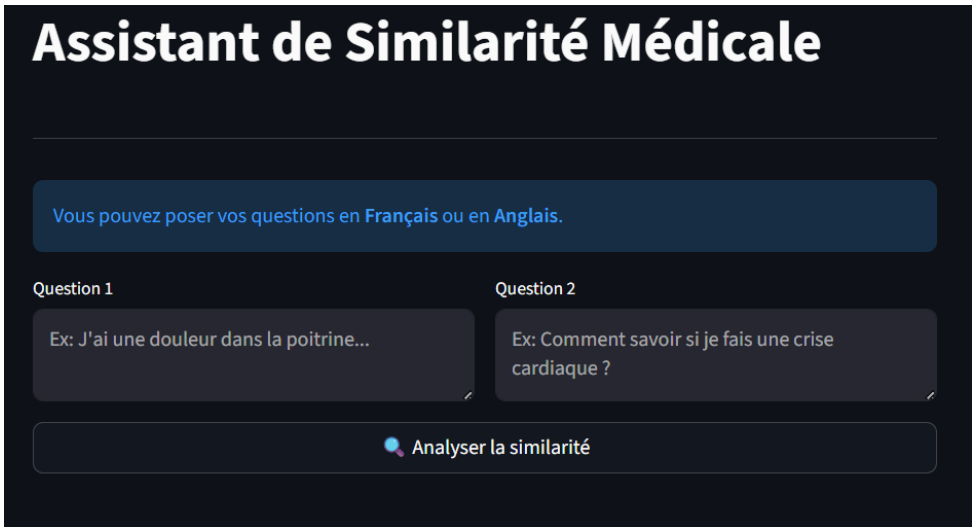


Figure 2: Interface permettant la saisie en langage naturel.

L'exemple suivant montre deux questions proches :

- Q1 : *"How can I lower my cholesterol naturally ?"*
- Q2 : *"What are the best ways to reduce high cholesterol without medication ?"*

Le système répond *SIMILAIRES* et affiche la traduction utilisée par le modèle, ce qui rend le résultat plus transparent.

6 Limites et perspectives

- **Pas de jeu de validation séparé.** Le jeu de test sert aussi à choisir le nombre d'époques. Le score de 83,77 % est donc un peu optimiste. Il faudrait un découpage en entraînement, validation et test.
- **Risque de fuite de données.** Une même question apparaît dans plusieurs paires. Un découpage par groupes de questions donnerait une mesure plus honnête.

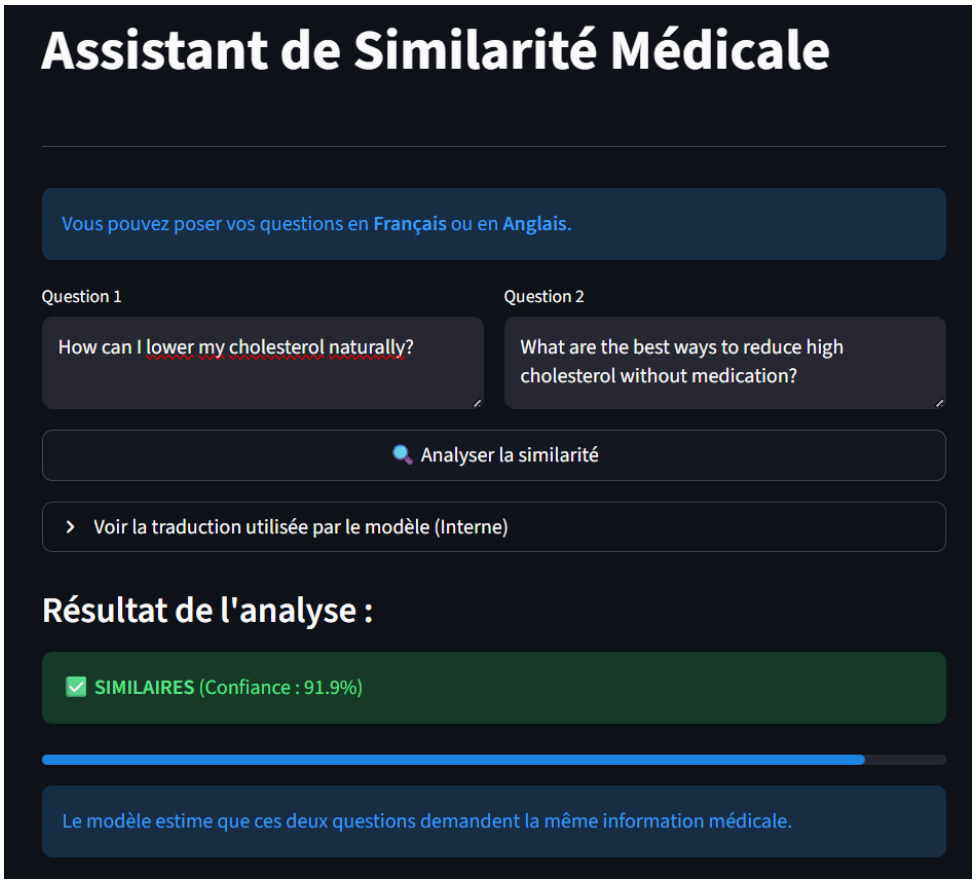


Figure 3: Prédiction avec un score de confiance de 91,9 %.

- **Une seule exécution.** Les résultats viennent d'un seul entraînement. Plusieurs graines aléatoires donneraient une moyenne et un écart-type.
- **Pas de baseline simple.** Comparer avec TF-IDF et régression logistique, ou avec BERT non spécialisé, montrerait l'apport de BioBERT.
- **Usage médical.** L'outil détecte des questions similaires. Il ne donne aucun conseil médical.

7 Conclusion

Ce projet montre l'intérêt du transfert d'apprentissage dans le domaine médical : BioBERT fine-tuné atteint 83,77 % d'accuracy et 0,84 de F1 sur un jeu équilibré. Le passage à PyTorch a stabilisé l'entraînement, et le remplacement de Google Translate par un modèle de traduction local rend l'application plus fiable et indépendante des services externes.