

Université Côte d'Azur

Master 1 Informatique - Parcours Intelligence Artificielle

Détection de Similarité Sémantique dans les Questions Médicales

Application du modèle BioBERT et Pipeline Multilingue

Auteur :

Ibrahima CAMARA

Technologies : PyTorch, Hugging Face, BioBERT, Streamlit

18 février 2026

Table des matières

1	Introduction	2
2	Architecture Technique	2
2.1	Le Modèle : BioBERT	2
2.2	Implémentation PyTorch	2
3	Analyse des Résultats	2
3.1	Courbe d'Apprentissage et Overfitting	2
4	Déploiement et Interface Utilisateur	4
4.1	Pipeline de Traduction (Multilinguisme)	4
4.2	Démonstration	4
5	Conclusion	5

1 Introduction

L'explosion des demandes sur les plateformes de télémédecine crée un besoin urgent d'automatisation. Un défi majeur est la redondance : les patients posent souvent la même question médicale mais avec des formulations très différentes.

Ce projet présente un système d'Intelligence Artificielle capable de détecter si deux questions sont sémantiquement équivalentes. Nous utilisons une approche de *Transfer Learning* basée sur **BioBERT**, fine-tunée sur un corpus médical, et déployée via une interface capable de gérer le multilinguisme (Français/Anglais).

2 Architecture Technique

2.1 Le Modèle : BioBERT

Nous avons choisi le modèle pré-entraîné `dmis-lab/biobert-base-cased-v1.2`. Contrairement au BERT standard, BioBERT a été entraîné sur des millions d'articles biomédicaux (PubMed), ce qui lui permet de comprendre des termes complexes comme "hypertension", "myocardial infarction" ou "analgesic".

2.2 Implémentation PyTorch

Pour garantir la stabilité de l'entraînement et la compatibilité avec les dernières bibliothèques de recherche, le projet a été migré de TensorFlow vers **PyTorch**. L'entraînement a été réalisé sur GPU (NVIDIA T4) via Google Colab.

```
1 # Param tres optimis s pour viter l'oubli catastrophique
2 training_args = TrainingArguments(
3     output_dir='./results',
4     num_train_epochs=3,           # Arr t pr coce (Early Stopping)
5     per_device_train_batch_size=16,
6     learning_rate=2e-5,          # Taux d'apprentissage fin
7     weight_decay=0.01,
8     evaluation_strategy="epoch"
9 )
```

Listing 1 – Configuration de l'entraînement PyTorch

3 Analyse des Résultats

3.1 Courbe d'Apprentissage et Overfitting

L'entraînement a été monitoré sur 10 époques. La figure ci-dessous illustre l'évolution de la fonction de perte (*Loss*) sur les jeux d'entraînement (bleu) et de validation (rouge).




FIGURE 1 – Analyse de la convergence : Détection du point de sur-apprentissage à l'époque 3.

Interprétation : Nous observons clairement un phénomène de sur-apprentissage (*overfitting*) à partir de l'époque 4. Alors que le modèle continue d'apprendre par cœur les données d'entraînement (la courbe bleue descend vers 0), sa capacité à généraliser sur de nouvelles données se dégrade (la courbe rouge remonte). **Décision :** Nous avons retenu le modèle à l'**époque 3**, qui offre le meilleur compromis avec une Validation Loss de ≈ 0.42 et une précision globale (*Accuracy*) de 83.7%.

4 Déploiement et Interface Utilisateur

Pour rendre le modèle accessible, nous avons développé une application web interactive avec **Streamlit**.

4.1 Pipeline de Traduction (Multilinguisme)

Le modèle BioBERT étant natif anglais, nous avons implémenté un pipeline de pré-traitement innovant. L'application détecte la langue de l'utilisateur (ex : Français) et traduit la requête à la volée vers l'anglais avant de l'envoyer au modèle. Cela permet aux patients francophones de bénéficier de la puissance de BioBERT.



FIGURE 2 – Interface utilisateur permettant la saisie en langage naturel.

4.2 Démonstration

L'exemple ci-dessous montre l'analyse de deux questions sémantiquement proches :

- Q1 : *"How can I lower my cholesterol naturally ?"*
- Q2 : *"What are the best ways to reduce high cholesterol without medication ?"*

Assistant de Similarité Médicale

Vous pouvez poser vos questions en Français ou en Anglais.

Question 1
How can I lower my cholesterol naturally?

Question 2
What are the best ways to reduce high cholesterol without medication?

Analyser la similarité

> Voir la traduction utilisée par le modèle (Interne)

Résultat de l'analyse :

✓ **SIMILAIRES** (Confiance : 91.9%)

Le modèle estime que ces deux questions demandent la même information médicale.

FIGURE 3 – Prédiction réussie avec un score de confiance de 91.9%.

Le système identifie correctement la similarité (Label "SIMILAIRES") et affiche la traduction interne utilisée pour l'inférence, garantissant la transparence de l'IA (Explainability).

5 Conclusion

Ce projet a permis de valider l'efficacité du transfert d'apprentissage dans le domaine médical. En migrant vers PyTorch et en résolvant les problèmes de compatibilité de dépendances, nous avons produit un modèle robuste. L'ajout d'une couche de traduction automatique rend l'outil universel, répondant ainsi aux besoins réels des systèmes de santé multilingues.